

claude-ollama, explicado para todos

Uma versão em linguagem simples do guia técnico — sem jargão, com analogias do dia a dia.

OmniForge · omniforge.com.br · versão 14/06/2026

Para quem é este guia

Este é o mesmo conteúdo do guia técnico original, porém reescrito para qualquer pessoa entender — mesmo sem nenhuma formação em tecnologia. Cada termo técnico vem acompanhado de uma explicação simples, e há um glossário no final. Você não precisa saber programar para acompanhar.

1. A ideia em uma frase

O **claude-ollama** é um **tradutor invisível** que permite usar uma ferramenta de programação chamada Claude Code com “cérebros” de inteligência artificial alternativos — geralmente mais baratos — sem que a ferramenta perceba a diferença.

Pense assim

Imagine um **intérprete simultâneo** numa reunião internacional. Você fala português; o intérprete traduz para o idioma do outro lado e traz a resposta de volta em português. Você nunca precisa aprender a outra língua. O claude-ollama faz exatamente isso — só que entre dois “idiomas” que computadores usam para conversar.

2. Por que isso existe

O problema que ele resolve é simples de entender quando separamos as peças:

- **A ferramenta principal (Claude Code)** normalmente conversa com os servidores da Anthropic, a empresa que criou o Claude. Cada conversa consome créditos pagos — uma espécie de saldo de uso.
- **Existem outros fornecedores de IA** na internet (como Ollama Cloud e Groq) que oferecem outros cérebros de inteligência artificial, muitas vezes por um custo menor.
- **O detalhe que trava tudo:** a ferramenta só sabe “falar” no formato da Anthropic, e esses outros fornecedores “falam” num formato diferente. É como dois aparelhos com tomadas incompatíveis.

A solução: o claude-ollama fica no meio e traduz, em tempo real, as duas formas de conversa. Assim você aproveita toda a inteligência da ferramenta usando cérebros alternativos, sem gastar o saldo da Anthropic.

3. Como funciona — a viagem de um pedido

Acompanhe o caminho que um pedido faz, do começo ao fim:

1. Você dá uma tarefa à ferramenta — por exemplo, “corrija este programa”.
2. A ferramenta prepara o pedido no “idioma Anthropic” e o entrega ao tradutor (o claude-ollama), que vive dentro do seu próprio computador.
3. O tradutor reescreve o pedido no “idioma” do outro fornecedor e o envia para o cérebro escolhido, apresentando um cartão de acesso (a chave).
4. A resposta volta aos poucos, e o tradutor a converte de volta para o “idioma Anthropic”.
5. A ferramenta recebe a resposta e segue trabalhando, achando que conversou com a Anthropic o tempo todo.

Por que o texto aparece aos poucos?

Essa entrega “pedaço por pedaço” é o que faz a resposta surgir gradualmente na tela, como uma legenda ao vivo — em vez de tudo de uma vez só. É proposital e deixa a experiência mais fluida.

4. As peças do sistema (quem é quem)

Por baixo, o sistema é um pequeno time com funções bem definidas. Em linguagem do dia a dia:

Peça	O que ela é, em linguagem simples
O tradutor	O intérprete que fica no meio e converte os dois idiomas. Mora no seu computador e é o coração de tudo.
A ponte de imagens	Um ajudante extra que só entra em cena quando o pedido inclui uma foto.
O cérebro local	Um modelo de IA que pode rodar dentro do seu próprio computador, sem depender da internet.
A barra de status	Um painelzinho na tela de comandos que mostra qual cérebro está ativo e se houve erros.
O cofre de chaves	Um arquivo trancado onde ficam guardados os cartões de acesso aos fornecedores.
O zelador	Um vigia automático que mantém o tradutor sempre ligado e o reinicia sozinho se ele cair.

5. Como ele escolhe qual cérebro usar

O sistema mantém uma “tabela de equivalências”. Quando a ferramenta pede um cérebro da Anthropic, o tradutor o substitui por um cérebro alternativo parecido. É como um cardápio de tradução: “se pedirem o prato A, sirvo o prato B, que é equivalente e mais em conta”.

Na prática, a escolha segue a dificuldade da tarefa:

- **Tarefas leves e rápidas** → um cérebro pequeno e ágil.
- **Trabalho pesado de programação** → um cérebro grande, especialista em código.
- **Raciocínio complexo** → o cérebro mais “pensador”, voltado a problemas difíceis.

Se preferir, você também pode pedir um cérebro específico chamando-o pelo apelido dele.

6. Planos B, C e D — quando algo dá errado

Uma das partes mais inteligentes do sistema é o que ele faz quando algo falha. São três redes de proteção, acionadas automaticamente:

1. **Reveza os cartões de acesso.** O sistema tem mais de uma chave e vai alternando entre elas. Se uma falha, ele tenta a próxima sem você perceber — como ter dois cartões no bolso.
2. **Troca de cérebro quando o fornecedor está lotado.** Se o cérebro escolhido está sobrecarregado (aquele famoso “muita gente usando agora”), ele tenta outro parecido em vez de simplesmente desistir.
3. **Aciona um fornecedor reserva.** Em último caso, recorre a um fornecedor de emergência (o Groq) — mas só para pedidos simples, porque pedidos muito grandes não cabem lá.

E o tal “erro 429”?

Quando você ouvir falar em “erro 429”, é só o jeito técnico de dizer “o sistema está cheio, tente de novo daqui a pouco”. O claude-ollama trata isso sozinho, trocando de cérebro nos bastidores.

7. E quando você manda uma imagem?

Nem todo cérebro de IA sabe “enxergar” imagens. Por isso existe uma **ponte especial**: quando o pedido inclui uma foto, ela percebe isso e, só naquele momento, encaminha o trabalho para um cérebro que entende imagens. Assim que o turno com foto termina, tudo volta ao normal.

8. Segurança — as chaves da casa

As chaves de acesso funcionam como as chaves da sua casa: quem as tem, entra. Por isso o sistema segue algumas regras de bom senso:

- **O arquivo de chaves fica trancado** — só o dono do computador consegue lê-lo.
- **Nunca se cola uma chave dentro do programa** nem se publica em lugar nenhum. Elas ficam guardadas em local seguro.
- **Trocar as chaves** só é obrigatório se elas vazarem para fora do lugar autorizado. Uma chave guardada num lugar privado e fechado não é motivo de alarme.

Tranquilidade

Neste guia, todas as chaves foram substituídas por marcadores do tipo “<SUA_CHAVE_...>”. Nenhuma senha ou chave real aparece em momento algum.

9. Como está hoje (junho de 2026)

- O tradutor está **ligado e sob vigilância automática** — se cair, reinicia sozinho.
- Há **duas chaves principais em rodízio** mais uma chave reserva de emergência.
- Uma terceira chave foi **retirada de circulação**: ela até “entrava”, mas não conseguia trabalhar por causa de uma pendência de cobrança na conta. Ela só volta quando essa conta for regularizada.
- A ponte de imagens **só liga quando é necessária**, para não consumir recursos à toa.

10. Glossário — tradução dos termos

Se em alguma conversa técnica aparecer um destes termos, aqui está a tradução para o português do dia a dia:

Termo técnico	O que significa, sem jargão
API	A “tomada de encaixe” pela qual dois programas conversam entre si.
Proxy / shim	O intérprete que fica no meio, traduz e repassa a conversa.
Anthropic	A empresa que cria o Claude.
Claude Code	A ferramenta de programação assistida por inteligência artificial.
Modelo de IA (“cérebro”)	O motor que de fato gera as respostas (GLM, Kimi, Qwen, DeepSeek e outros).
Ollama Cloud / Groq	Fornecedores que “alugam” acesso a esses cérebros pela internet.
Cota / quota	O saldo de uso pago de um serviço.
Chave (API key)	O cartão de acesso que prova que você tem permissão para usar um serviço.
Round-robin	Revezar entre várias opções, uma de cada vez.
Fallback	O plano B automático, acionado quando a opção principal falha.
Erro 429	Um aviso de “sistema cheio, tente novamente daqui a pouco”.
Streaming	A resposta chegando aos poucos, como uma legenda ao vivo.
Porta (ex.: 11439)	O “número da sala” onde um programa atende, dentro do computador.
Localhost / 127.0.0.1	O endereço que significa “aqui mesmo, no meu próprio computador”.
Terminal	A tela de comandos por texto, geralmente com fundo escuro.
Vision	A capacidade de a IA “enxergar” e interpretar imagens.

Jessé Freitas

OmniForge · omniforge.com.br